
ことは

話して、覚えて、時々忘れる。
Windowsで動く、個人用AIパート
ナー。

Document v2.0 / 2026.09.18
Source baseline: main@2604b89



会話AIに、記憶と時間の流れを。

会話AIに、記憶と時間の流れを。

MEMORY

1. 人のように、覚えて、忘れる

会話から出来事や好みを抽出し、記憶として整理します。思い出した記憶は保持期間が延び、長く使われない記憶は期限後に自動削除されます。

想起された記憶は再固定化候補となり、次の整理で再確認・更新できます。

VOICE

2. 声で話せる

AivisSpeech互換エンジンで返答を読み上げます。音声入力ブラウザのWeb Speech APIを使い、入力・応答・読み上げを繰り返して通話できます。

読み上げ中はマイクを閉じ、音声の回り込みを防ぎます。

RECALL

3. 違う言葉でも、思い出せる

作業記憶、エピソード記憶、意味記憶を使い分けます。タグ一致、記憶間の接続、Ollama bge-m3 の意味検索を組み合わせます。

意味記憶は fact / preference / open_topic / procedure。

実装上、「手続き記憶」は独立レイヤーではなく、意味記憶の procedure 種別です。



保存はローカル。外部送信は必要な処理だけ。

保存はローカル。 外部送信は必要な処理だけ。

CONTROL

4. 安全なPC操作

PCの状態確認、音声エンジンやOllamaの起動・停止、ことは本体の再起動など、あらかじめ定義した操作だけを実行します。

任意のOSコマンドをAIが生成・実行する構成ではありません。実行可能操作は `talk/actions.py` に定義し、記録は `data/actions.log` に残します。

LOCAL FIRST

5. ローカル保存を中心に

会話と記憶の保存先はローカルSQLite。意味検索もOllamaを使い、PC内で処理します。

Gemini APIには応答生成・記憶整理に必要な会話と記憶の一部だけを送信します。音声認識はWeb Speech API、通知はOneSignalを利用します。

Reading Guide

対象	章	内容
一般ユーザー	II - IV	できること、画面、仕組み
実装・保守担当	V - VII	構成、処理フロー、DB/API、運用

できること

CAPABILITIES

ことはが できること

会話。

記憶。

音声・通知。

PC操作。



日常のやり取りを、4つの機能で支える。

日常のやり取りを、 4つの機能で支える。

カテゴリ	代表機能	一言
会話	Web / CUI、Fast/Slow、機嫌・時間帯	直近の文脈を踏まえて応答
記憶	抽出、想起、再固定化、忘却、保護	必要な記憶を残し、古い記憶は忘れる
音声・通知	読み上げ、通話、リマインド、Web Push	声で話し、必要なときに通知
管理	設定、記憶編集、PC状態、再起動	必要な範囲だけ確認・操作

会話

- ブラウザとCUIの両方から利用
- 直近会話を参照
- 現在時刻、前回からの間隔、時間帯、機嫌を反映
- Fast/Slowルートを用意。既定はSlow

記憶

- エピソード・意味記憶を整理
- タグ、接続、ベクトルで想起
- よく使う記憶は期限を延長
- 保護、本文修正、明示削除に対応



記憶は「保存する」だけでなく、「使われ方」で残り方が変わる。

記憶は「保存する」だけでなく、 使われ方で残り方が変わる。

作業記憶

messages の直近会話。既定は5往復、最大3,000文字をプロンプトに含めます。

エピソード記憶

layer = episode
kind = event


出来事。新規時の保持期間は既定30日。

意味記憶

layer = semantic

fact / preference / open_topic /
procedure
保持期間は既定180日。

記憶の保持



期限切れ経路は線種でも区別し、色だけに意味を依存させません。



声で話し、必要なタイミングで知らせ、設定やPC状態を管理する。

声で話し、必要なタイミングで知らせ、 必要な範囲だけ管理する。

音声・通知

- AivisSpeech互換エンジンによる読み上げ
- Web Speech APIによる音声入力
- 通話は1台を所有者として管理
- リマインド / Web Push
- 音声エンジン / Ollama停止通知
- Cドライブ空き容量警告
- 朝のひとこと、見守り、暇なときの声かけ

管理

- Web設定画面から9項目を変更
- 人格・固定ルール・記憶整理プロンプトを編集
- 記憶の参照、修正、保護、削除
- 頼まれごとの確認・取り消し
- PCの状態確認
- 通話所有権の解除 / アプリ再起動

安全側の設計

AIが任意のOSコマンドを組み立てるのではなく、`talk/actions.py` の定義済み操作だけを実行します。



INTERFACES

コントロール範囲は 必要最小限。

ブラウザ。

ターミナル。


タスクトレイ。

設定シート。



会話は中央。操作は必要なときだけ。

会話は中央。 操作は必要なときだけ。



Web Chat

- 1 キャラクター**
時間帯に応じてアバターを切り替え。瞬き差分を持つ。
- 2 会話履歴**
GET /api/history。既定40メッセージ。
- 3 処理モード**
/api/chat の mode を表示。
- 4 入力**
PCはEnter送信。タッチ端末はEnterを改行。
- 5 通話**
対応ブラウザのみ。音声入力と読み上げを反復。
- 6 設定**
プロンプト、設定、記憶、頼まれごと、PC状態へ。

必要なときだけ開き、普段はタスクトレイに常駐する。

必要なときだけ開き、 普段はタスクトレイに常駐する。

CUI

```
しょうや: 昨日の続き、覚えてる？  
ことは : うん。前に話してた件だね。
```

```
> /status  
DB: data/kotoha.sqlite3  
model: gemini-3.5-flash-lite  
status: ready
```

テキスト会話、手動整理、バックアップ、記憶管理、status確認に対応。

タスクトレイ

ことは

ことはを開く

手を貸す

ことは / 音声エンジン / Ollama の状態

入れ直す

終わる

左クリックで会話画面を開きます。状態は10秒ごとに更新され、停止時は別アイコン `kotoha_off.ico` を使用します。

日常的な調整はWebから。詳細設定は .env から。

日常的な調整はWebから。 詳細設定は .env から。

設定シート - Webから変更できる9項目

グループ	項目
話し方	KOTOHA_TEMPERATURE , KOTOHA_MAX_OUTPUT_TOKENS
覚えること	KOTOHA_RECENT_TURNS , KOTOHA_RECENT_CHARS , KOTOHA_IDLE_SECONDS
声	KOTOHA_VOICE_STYLE_ID
ことはから	KOTOHA_BRIEFING_ENABLED , KOTOHA_LOOKOUT_ENABLED , KOTOHA_REACH_OUT_ENABLED

変更内容は .env へ保存し、その場で設定を再読み込みします。

記憶管理

- 意味記憶 / できごと / 保護を切替
- 各一覧最大40件
- 本文編集 / 保護切替 / 明示削除
- タグと根拠発言IDを詳細画面で確認

本文を修正すると

確認日時と期限を更新し、既存ベクトルを破棄。次回巡回で再生成します。

ことはの内部で起きていることを、4つの流れで見る。

HOW IT WORKS

会話処理の流れ

ことはの内部で起きていることを、4つの流れで見る。

会話。

記憶。

音声。


データ管理。



会話中にすべてを整理せず、会話が落ち着いてから記憶をまとめる。


会話中にすべてを整理せず、 落ち着いてから記憶をまとめる。

会話



- ユーザー入力はLLM呼び出しより先に保存
- 生成に失敗しても入力に残る
- 返答から内部タグ [USED:] [MOOD:] [REMIND:] [DO:] を除いて表示

記憶



Webでは会話が5分途切れた後に整理。会話中に記憶本文を直接更新しません。



ローカル中心。ただし、外部サービスへ渡る情報を明確に分ける。

ローカル中心。 外部サービスへ渡る情報を明確に分ける。

音声通話



- 音声入力: Chrome / EdgeのWeb Speech API
- 読み上げ: ローカルAivisSpeech互換エンジン
- 読み上げ中はマイクを開かない / 割り込み発話は未対応

データの扱い

レーン	データ	主な送信先
ローカル	会話原文、記憶、タグ、接続、ベクトル、バックアップ	SQLite / Ollama / AivisSpeech
クラウド	応答生成・整理に必要な会話と記憶	Gemini API
クラウド	音声認識時の音声	ブラウザの音声認識サービス
クラウド	通知本文。無効化可能	OneSignal

`KOTOHA_PUSH_SHOW_TEXT=false` ならOneSignalへ通知本文を渡さず、「ことはから」のみ表示します。



ARCHITECTURE

アプリが壊れても、 記憶は消えない。

会話と記憶はSQLiteへ保存。補助機能や外部サービスは、会話処理との境界を分けて接続します。



1つのローカルアプリを中心に、必要な外部機能だけ接続する。

1つのローカルアプリを中心に、必要な外部機能だけ接続する。



技術スタック

項目	実装	項目	実装
言語	Python 3.10+	DB	SQLite
Web API	FastAPI	HTTP	httpx
Webサーバー	uvicorn	LLM	Gemini API OpenAI互換
既定モデル	gemini-3.5-flash-lite	音声	AivisSpeech互換
ベクトル	Ollama bge-m3	リモート / Push	Tailscale Serve / OneSignal



会話・記憶・配信の責務を分け、変更範囲を追いやすくする。

会話・記憶・配信の責務を分け、 変更範囲を追いやすくする。

```
kotoha/  
  launcher.py  
  cli.py  
  config.py  
  settings.py  
  talk/  
    chat.py  
    llm.py  
    router.py  
    actions.py  
    presence.py  
    weather.py  
  memory/  
    db.py  
    retrieve.py  
    consolidate.py  
    embed.py  
    remind.py  
  serve/  
    web.py  
    jobs.py  
    announce.py  
    voice.py  
    admin.py  
    static/
```

モジュール	責務
launcher.py	起動前確認、Tailscale Serve、ブラウザ表示
talk/chat.py	会話保存、プロンプト生成、返答処理、機嫌
talk/router.py	Fast / Slow判定
talk/llm.py	Gemini API通信
memory/retrieve.py	記憶想起
memory/consolidate.py	記憶整理・再固定化
memory/embed.py	ベクトル生成・類似度・接続
memory/db.py	スキーマ、DB操作、忘却、バックアップ
serve/web.py	内部Web API
serve/jobs.py	60秒巡回、排他制御
serve/announce.py	自発発言と通知の唯一の入口
serve/voice.py	AivisSpeech連携
serve/admin.py	Web設定・プロンプト編集

保守時は、どの処理フローで問題が起きているかから追う。

保守時は、どの処理フローで問題が起きているかから追う。

フロー	入口	主な実装	詳細
会話生成	/api/chat , CUI	talk/chat.py , router.py , llm.py	Page 20
記憶抽出・整理	idle / CUI / command	memory/consolidate.py	Page 21
記憶想起	会話生成中	retrieve.py , embed.py	Page 22
忘却・保守	24h / CUI終了	memory/db.py , serve/jobs.py	Page 23
DB	全機能	memory/db.py	Page 24-25
Web API	Web UI	serve/web.py	Page 26
バックアップ	24h / command	memory/db.py	Page 29

排他制御

Web会話とバックグラウンド処理は同一プロセスの `threading.Lock` を共有します。別プロセスのCUIや管理コマンドとの排他にはなりません。

DEEP DIVE


入力から、返答まで。 覚えてから、忘れるまで。

この章では、実装を処理単位で追います。



入力を先に残し、必要な文脈だけ組み立てて生成する。

入力を先に残し、必要な文脈だけ組み立てて生成する。



ステップ仕様

1. `turn_id = MAX(turn_id) + 1`
2. ユーザー入力を保存して即コミット
3. 直近 `KOTOHA_RECENT_TURNS × 2` を取得
4. `KOTOHA_RECENT_CHARS` 超過分を古い順に除外
5. Fast / Slowを判定
6. Slowでは関連記憶を取得
7. 1件のuserメッセージとしてGeminiへ送信
8. 内部タグを解析・除去
9. 返答、機嫌、利用記憶、再固定化候補を保存

プロンプト組み込み順

1. `fixed_rules.txt`
2. `persona.txt`
3. 時刻 / 曜日 / 間隔 / 時間帯 / 機嫌
4. 保護記憶 最大5件
5. 関連記憶 最大6件
6. 必要時のみPC状態と実行可能アクション
7. 直近会話
8. 今回の入力

Fast / Slow

```
FAST_ENABLED=false -> slow
入力 > FAST_MAX_CHARS -> slow
QUESTION_WORDS / PAST_WORDS / OP_WORDS -> slow
登録済みタグと一致 -> slow
それ以外 -> fast
```


Fastは保護記憶だけを渡します。1行目が `NEEDS_SEARCH` の場合、同じターンをSlowで再生成し `slow+fallback` とします。

エラー

- 通信エラー / 5xx / 空応答: 既定2回まで再試行
- 429: 再試行せずエラー
- 400 / 401: 即エラー
- 応答形式不正: 即エラー
- Web: HTTP 502
- 入力に残るが、失敗した返答は保存しない

会話中に直接書き換えず、まとめて整理する。

会話中に直接書き換えず、 まとめて整理する。



実行タイミング

経路	条件
CUI起動時・返答後	未処理10ターン以上
CUI /consolidate	無条件
Web巡回	60秒ごと。未処理あり + 最終会話から300秒超
kotoha.bat consolidate	無条件

1回の処理は最大20ターン / 20,000文字。新規記憶は最大8件、更新は最大4件。

分類基準

layer	kind	上限
episode	event	400字
semantic	fact / preference / open_topic / procedure	200字

タグ生成

- LLM出力の `tags` を使用
- 1ノード最大3個
- 前後空白を除去、連続空白を正規化
- 1タグ最大24文字、重複除外

接続生成


- 整理時: 新規ノード同士の `derived_from`
- ベクトル巡回時: 類似記憶間の `related_to`
- 自己接続禁止
- `related_to` は0.80以上、1ノード最大3本

重複候補

新規候補をベクトル化し、既存記憶との類似度が 0.90 以上なら新規作成せず、既存ノードを再確認します。

1つの総合スコアではなく、検索方式ごとに役割と枠を分ける。

1つの総合スコアではなく、 検索方式ごとに役割と枠を分ける。



方式	実装	閾値 / 上限
タグ	文字列部分一致	候補40件
接続	タグ候補から1 hop	40件
最近	episode / open_topic	10件
ベクトル	Ollama bge-m3	cos 0.62以上、最大2件
保護	pinned=1	別枠5件
最終関連記憶	統合	6件

統合方式

- 「タグ0.4 + ベクトル0.6」のような重み付き総合スコアはなし
- 6枠のうち既定2枠をベクトル検索用に予約
- 残りをタグ / 接続 / 最近の候補が順に埋める
- ベクトル候補がなければ予約枠を通常候補へ戻す
- タグ候補は use_count、last_used_at、confirmed_at で優先


ベクトル仕様

- モデル: bge-m3 / 1024次元
- 保存: 正規化済み float32 BLOB、4,096 bytes
- 類似度: 単位ベクトル内積 = コサイン類似度
- クエリ: 直前2行 + 今回の発言
- 本文最大400文字 / timeout 1.5秒
- 失敗後リトライ抑制60秒

KOTOHA_EMBED_FLOOR=0.62 は実測から置かれた暫定値。

思い出した記憶は保持期間が延び、長く使われない記憶は期限後に削除される。

思い出した記憶は保持期間が延び、 長く使われない記憶は期限後に削除される。



期限

- episode: 30日 / semantic: 180日
- 新規時は最初の有効な根拠発言日時を基準
- 想起・再確認・本文更新時に同じ日数を延長
- MAX(既存期限, 新期限) のため短縮しない
- expires_at IS NULL は無期限

保護フラグ

pinned は自動削除を防ぐフラグ。本文更新や明示削除を禁止せず、期限切れ記憶を想起対象へ戻す機能でもありません。

定期メンテナンス

1. pinned=0 かつ期限切れ記憶を削除
2. 30日未使用タグの use_count を0へ
3. last_forget_at を更新

Webは既定24時間ごと、CUIは終了時。

再固定化

[USED:id] のIDを pending_reconsolidation_ids に最大50件保持。次回整理で既存記憶として渡し、再確認・更新できます。

会話原文と記憶を分離し、根拠を辿れる構造にする。

会話原文と記憶を分離し、 根拠を辿れる構造にする。

messages id PK turn_id role text created_at extractable	memory_nodes id PK layer kind text occurred_at confirmed_at last_used_at expires_at pinned source_summary source_key	memory_sources node_id PK message_id PK
memory_tags node_id PK tag PK use_count last_used_at last_used_turn_id	memory_edges from_id PK to_id PK relation PK	memory_vectors node_id PK model vector BLOB
reminders id PK due_at text created_at done_at	app_state key PK value	

バックアップ履歴について

backup_history のようなDBテーブルはありません。実体は `data/backups/kotoha_*.sqlite3`、最終自動バックアップ時刻は `app_state.last_backup_at`、保持数は `KOTOHA_BACKUP_KEEP` で管理します。

制約をDB側にも置き、壊れた状態を作りにくくする。

制約をDB側にも置き、壊れた状態を作りにくくする。

主な制約

テーブル	制約
messages	UNIQUE(turn_id, role)、roleは user/assistant
memory_nodes	source_key UNIQUE、layer/kind整合性CHECK
memory_edges	(from_id,to_id,relation) PK、自己接続禁止
memory_tags	(node_id,tag) PK、use_count 0-3
memory_sources	(node_id,message_id) PK
memory_vectors	node_id PK、ノード削除時 CASCADE

インデックス

- messages(created_at, id)
- memory_tags(tag, node_id)
- memory_nodes(expires_at)
- memory_nodes(layer, confirmed_at)
- memory_edges(from_id, relation)
- memory_edges(to_id, relation)
- memory_sources(message_id, node_id)
- reminders(done_at, due_at)

記憶ライフサイクル

会話 -> 整理候補 -> 検証 -> memory_nodes -> tags / sources / edges
-> vector生成 -> 想起 -> last_used_at + expires_at延長
-> 再固定化候補 -> reconfirm / update -> 未使用なら期限切れ -> maintenanceで削除


削除時、接続・タグ・出典・ベクトルは外部キーCASCADEで削除。会話原文とバックアップは残ります。

UI用APIはトークンで保護し、外部サービス連携を明確な境界に集約する。

UI用APIはトークンで保護し、外部サービス連携を明確な境界に集約する。

認証

/、静的ファイル、OneSignal Service Workerを除くWeb APIは X-Kotoha-Token を検証。ブラウザは認証成功後、トークンを localStorage に保持。



Gemini / Ollama

- Gemini Base: .../v1beta/openai
- Endpoint: /chat/completions
- 既定モデル: gemini-3.5-flash-lite
- 会話上限1024 / 整理上限1500 / timeout 60秒 / retry 2
- Ollama: 127.0.0.1:11434/api/embed
- Model: bge-m3 / 1024次元

主要エンドポイント

Method	Path	用途	Method	Path	用途
GET	/api/history	会話履歴	POST	/api/chat	会話
POST	/api/speak	audio/wav	GET/POST/DELETE	/api/call	通話所有権
GET	/api/memories	記憶一覧	GET/PUT/DELETE	/api/memories/{id}	記憶詳細
GET	/api/reminders	未完了リマインド	POST	/api/reminders/snooze	再通知
GET/PUT	/api/settings	9設定	GET	/api/machine	PC状態
GET	/api/push	OneSignal App ID	POST	/api/restart	再起動要求

保守注記: Googleの2026-07-21リリースノートではGemini 3.xのsampling parameterにdeprecated注記あり。現実装の互換性は将来確認項目。

運用・保守・付録

OPERATIONS

**普段は触らない。
必要なときに、すぐ確認できる。**

設定、起動、復元、障害切り分けを1か所にまとめます。



初期値は `.env.example` に一元化する。

初期値は `.env.example` に一元化する。

項目	初期値	変更	項目	初期値	変更
GEMINI_MODEL	gemini-3.5-flash-lite	.env	KOTOHA_WEB_PORT	8000	.env
KOTOHA_MAX_OUTPUT_TOKENS	1024	.env / Web	KOTOHA_RECENT_TURNS	5	.env / Web
KOTOHA_TIMEOUT_SECONDS	60	.env	KOTOHA_RECENT_CHARS	3000	.env / Web
KOTOHA_LLM_ATTEMPTS	2	.env	KOTOHA_IDLE_SECONDS	300	.env / Web
KOTOHA_WEB_TOKEN	空	.env	KOTOHA_EPISODE_DAYS	30	.env
KOTOHA_SEMANTIC_DAYS	180	.env	KOTOHA_RELATED_LIMIT	6	.env
KOTOHA_PINNED_LIMIT	5	.env	KOTOHA_EMBED_MODEL	bge-m3	.env
KOTOHA_EMBED_FLOOR	0.62	.env	KOTOHA_EMBED_RESERVE	2	.env
KOTOHA_BACKUP_KEEP	7	.env	KOTOHA_BACKUP_INTERVAL_SECONDS	3600	.env
KOTOHA_MAINTENANCE_SECONDS	86400	.env	KOTOHA_VOICE_BASE_URL	127.0.0.1:10101	.env
KOTOHA_VOICE_STYLE_ID	1878365376	.env / Web			

Gemini無料枠

2026-09-18時点で、原稿では `gemini-3.5-flash-lite` をFree Tier対象として整理しています。RPM / TPM / RPDは固定値を資料に載せず、Google AI StudioのActive rate limitsを正とします。

レート超過時、ことははHTTP 429を再試行せず呼び出し元へ返します。

起動と復元は単純に。障害時は、保存・通信・補助機能を分けて切り分ける。

起動と復元は単純に。 障害時は、保存・通信・補助機能を分けて切り分ける。


セットアップ

- 1. WindowsへPython 3.10以上を用意
 - 2. setup.bat で仮想環境と依存関係を準備
 - 3. settings.bat で .env を作成・編集
 - 4. GEMINI_API_KEY と KOTOHA_WEB_TOKEN を設定
 - 5. start.bat を実行
 - 6. 必要に応じてAivisSpeech、Ollama、Tailscaleを導入
- 通常起動は start.bat。常駐は kotoha.bat tray。ログイン時常駐は kotoha.bat autostart on。

ログ

- 操作: data/actions.log
- 通知: data/notify.log
- Web詳細: KOTOHA_DEBUG=true

バックアップ復元



バックアップに .env とプロンプトは含まれません。会話・記憶を含むため、元DBと同じ機密度で扱います。
Sources: README / docs/01-05 / docs/07 / current implementation, baseline main@2604b89

よくある症状

症状	確認
APIキー未設定	GEMINI_API_KEY
fastapi / uvicorn不足	setup.bat
no such table	DB初期化 / DB PATH
Webトークン無効	.envと画面入力
認証・モデルエラー	APIキー / モデルID
429	Gemini Active rate limits
音が出ない	AivisSpeech / 10101番
意味検索しない	Ollama / bge-m3 / 11434番
通知が届かない	PWA購読 / OneSignal / notify.log

